Probabilités et Statistique Avancées 1

Deuxième année Ensimag, Grenoble INP – UGA

Christophe Dutang, Pierre Etoré, Olivier Gaudoin, Hervé Guiol

Année universitaire 2026-2027

Table des matières

Tables des matières **2**

1 Espérance conditionnelle et processus stochastiques **5**

1.1 Rappels de probabilité 6

1.2 Notions d'espérance conditionnelle 7

1.3 Espérance conditionnellement à une tribu 9

1.4 Processus stochastiques 14

2 Chaines de Markov **18**

2.1 Définitions équivalentes des chaines de Markov 19

2.2 Mesures d'équilibre 26

2.3 Classification des états et décomposition 31

2.4 Convergence des chaines de Markov 39

3 Martingales **42**

3.1 Définitions des martingales 43

3.2 Temps d'arrêt et théorèmes d'arrêt 46

3.3 Résultats de convergence 49

3.4 Décomposition de Doob 53

4 Processus de Poisson **54**

4.1 Définitions et propriétés d'un processus de Poisson . . . 55
4.2 Propriétés au cours du temps . . . 57
4.3 Simulation . . . 59
4.4 Superposition . . . 61
4.5 Martingalité et convergence . . . 63

5 Application au modèle Cramér-Lundberg 65

5.1 Processus de risque . . . 66
5.2 Modèle de Cramér-Lundberg – première propriétés . . . 69
5.3 Formule de ruine – approche par la théorie de renouvellement . . . 74
5.4 Approximation et bornes de Cramér-Lundberg . . . 79

6 Estimation non-paramétrique de quantitées réelles 82

6.1 Loi des statistiques d'ordre et de rang et loi empirique . . . 83
6.2 Estimation de l'espérance d'un échantillon . . . 89
6.3 Estimation de la variance d'un échantillon . . . 91
6.4 Estimation des moments de tout ordre . . . 92
6.5 Estimation des quantiles . . . 93

7 Estimation fonctionnelle 96

7.1 Estimation de la fonction de répartition . . . 98
7.2 Estimation de la densité . . . 100

8 Théorie des valeurs extrêmes 107

8.1 Introduction . . . 108
8.2 Loi asymptotique du maximum d'un échantillon . . . 109
8.3 Approche par les excès . . . 113
8.4 Inférence statistique . . . 113

8.5 Conclusion 116

9 Tests d'adéquation, tests non-paramétriques à un échantillon **117**

9.1 Tests d'adéquation basés sur la fonction de répartition empirique 118

9.2 Tests non paramétriques sur un échantillon 124

Bibliographie **133**

Chapitre 1

Espérance conditionnelle et processus stochastiques

1.1 Rappels de probabilité **6**
1.2 Notions d'espérance conditionnelle **7**
1.2.1 Espérance conditionnellement à un évènement 7
1.2.2 Espérance d'une variable aléatoire conditionnellement à une autre : cas discret . . 7
1.2.3 Espérance d'une variable aléatoire conditionnellement à une autre : cas à densité bivariée 8
1.3 Espérance conditionnellement à une tribu **9**
1.3.1 Première approche : le cadre L^2 9
1.3.2 Extension au cadre L^1 et premières propriétés 10
1.3.3 Espérance d'une variable aléatoire conditionnellement à une autre 12
1.3.4 Autres propriétés 14
1.4 Processus stochastiques **14**
1.4.1 Définitions usuelles 16
1.4.2 Propriété de Markov 16
1.4.3 Deux exemples usuels 17

Dans ce chapitre, on rappelle les notions d'espérance conditionnelle déjà rencontrées en PS1 et PS2. On introduit une notion d'espérance conditionnelle plus générale : l'espérance conditionnellement à une tribu. Cette nouvelle notion englobe les précédentes, en les plaçant dans un cadre commun.

Dans tout ce chapitre, un espace de probabilités $(\Omega, \mathcal{F}, \mathbb{P})$ est donné et les variables aléatoires rencontrées sont définies sur cet espace de probabilités, où Ω est l'univers, $\mathcal{F}$ est une tribu et $\mathbb{P}$ la mesure de probabilité.

1.1 Rappels de probabilité

Définition 1.1.1 (variable aléatoire réelle)**.** *Une variable aléatoire réelle X est une application mesurable de $(\Omega, \mathcal{F})$ vers $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, i.e.,*

$$\forall B \in \mathcal{B}(\mathbb{R}), X^{-1}(B) \in \mathcal{F}.$$

En pratique, $X^{-1}(B) = \{X \in B\}$ est appelé évènement. A tout évènement, on peut associer une probabilité. La loi de probabilité de X est la mesure image $\mathbb{P}_X$ de $\mathbb{P}$ par l'application X. On rappelle que $\sigma(X)$ est la plus petite tribu (au sens inclusion) rendant X mesurable et $\sigma(X) = \{X^{-1}(B), B \in \mathcal{B}(\mathbb{R})\}$.

Définition 1.1.2 (variable aléatoire intégrable)**.** *Soit X une variable aléatoire réelle. X est intégrable lorsque $\mathbb{E}(|X|)$ est fini. Dans ce cas $\mathbb{E}(X) = \mathbb{E}(X_+) - \mathbb{E}(X_-)$ où $X_+ = \max(X, 0)$ et $X_- = -\min(X, 0)$ sont les parties positive et négative de X.*

Théorème 1.1.1 (Théorème de transfert)**.** *Soit X une variable aléatoire réelle. Soit $g : \mathbb{R} \mapsto \mathbb{R}$ une application mesurable. On a l'égalité suivante*

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x)\mathbb{P}_X(dx),$$

lorsque g est à valeurs positives ou g est intégrable $g \in \mathcal{L}^1(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P}_X)$.

Si X est à valeurs entières, alors

$$\mathbb{E}[g(X)] = \sum_{x \in \mathbb{N}} g(x)\mathbb{P}(X = x),$$

Si X est continue et de densité f_X, alors

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) f_X(x) dx.$$

Dans le cas d'une variable mixte, on somme les contributions discrètes et les contributions à densité.

Le tableau 1.1 liste les différentes caractérisations et les propriétés usuelles des variables aléatoires.

Définition 1.1.3 (variable aléatoire $\mathcal{H}$-mesurable)**.** *Soient X une variable aléatoire réelle et $\mathcal{H}$ une tribu. X est $\mathcal{H}$-mesurable lorsque pour tout $B \in \mathcal{B}(\mathbb{R})$, $X^{-1}(B) \in \mathcal{H}$.*

Définition 1.1.4 (variable aléatoire indépendante de $\mathcal{H}$)**.** *Soient X une variable aléatoire réelle et $\mathcal{H}$ une tribu. X est indépendant de $\mathcal{H}$ lorsque pour tout $A \in \mathcal{H}$, X et 1_A sont des variables aléatoires indépendantes, i.e., $\mathbb{P}(\{X \in \mathcal{B}\} \cap A) = \mathbb{P}(X \in \mathcal{B})\mathbb{P}(A)$.*

caractérisation	définition	commentaires
fonction de répartition	$F_X(x) = \mathbb{P}(X \leq x) = \mathbb{P}_X(]-\infty, x])$	
densité de probabilité	$f_X(x) = F'_X(x)$	si elle existe
fonction de masse de proba.	$\mathbb{P}(X = x)$	utile si non nulle
fonction caractéristique	$\varphi_X(t) = \mathbb{E}[e^{itX}]$	toujours définie

moments (s'ils existent)	définition	commentaires
moment ordinaire	$m_k(X) = \mathbb{E}[X^k]$	m_1 est l'espérance
moment centré	$\mu_k(X) = \mathbb{E}[(X - \mathbb{E}(X))^k]$	μ_2 est la variance

TABLE 1.1 – notation et définition pour les variables aléatoires

1.2 Notions d'espérance conditionnelle

1.2.1 Espérance conditionnellement à un évènement

Soit $A \in \mathcal{F}$ avec $\mathbb{P}(A) > 0$. On note $\mathbb{P}(\cdot \mid A)$ la mesure de probabilité définie sur $(\Omega, \mathcal{F})$ par

$$\forall B \in \mathcal{F}, \quad \mathbb{P}(B \mid A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)}.$$

C'est une mesure de probabilités sur $(\Omega, \mathcal{F})$ au même titre que $\mathbb{P}$. Elle a la particularité d'attribuer la masse 1 à l'évènement A et la masse 0 à tout $B \in \mathcal{F}$ t.q. $B \cap A = \emptyset$. On l'appelle la mesure de probabilités sachant A.

Soit X v.a. On définit l'espérance de X sachant l'évènement A comme l'intégrale de X contre $\mathbb{P}(\cdot \mid A)$. On a

$$\mathbb{E}_A(X) = \mathbb{E}(X|A) \stackrel{\triangle}{=} \int_\Omega X(\omega)\mathbb{P}(d\omega \mid A) = \frac{\int_A X(\omega)\mathbb{P}(d\omega)}{\mathbb{P}(A)} = \frac{\mathbb{E}(\mathbf{1}_A X)}{\mathbb{P}(A)}.$$

(les deux premiers termes de l'égalité sont parmi les notations possibles pour l'espérance de X sachant A).

1.2.2 Espérance d'une variable aléatoire conditionnellement à une autre : cas discret

Soient X et Y deux variables aléatoires, dont Y discrète. Pour faciliter l'exposé des choses on va aussi supposer que X est discrète.

Plus précisément : X et Y sont à valeurs respectivement dans E et E' dénombrables et on a $\mathbb{P}(X = x) > 0, \forall x \in E$, et $\mathbb{P}(Y = y) > 0, \forall y \in E'$.

On souhaite définir l'espérance de X sachant Y. Pour tout $y \in E'$ on définit

$$\mathbb{E}(X|Y = y) \stackrel{\triangle}{=} \mathbb{E}(X \mid \{Y = y\}) = \frac{\mathbb{E}[X\mathbf{1}_{\{Y=y\}}]}{\mathbb{P}(Y = y)} = \sum_{x \in E} x\mathbb{P}(X = x|Y = y). \tag{1.1}$$

Ici, on a utilisé simplement la définition vue à la sous-section 1.2.1 de l'espérance de X conditionnellement à l'événement $\{Y = y\}$. Cela a un sens puisque $\mathbb{P}(Y = y) > 0$ pour tout $y \in E'$.

En notant ensuite $\varphi(y) = \mathbb{E}(X|Y=y)$, $y \in E'$, on définit la v.a.

$$\mathbb{E}(X|Y) \stackrel{\triangle}{=} \varphi(Y).$$

Notons que comme φ est mesurable, la v.a. $\mathbb{E}(X|Y)$ est $\sigma(Y)$-mesurable.

1.2.3 Espérance d'une variable aléatoire conditionnellement à une autre : cas à densité bivariée

Soit (X,Y) à valeurs dans $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$ et de loi à densité bivariée $f_{X,Y}(x,y)$.

On rappelle que cela signifie que $\mathbb{P}_{X,Y}(dx,dy) = f_{X,Y}(x,y)\,dx\,dy$, en d'autres termes

$$\forall B \times C \in \mathcal{B}(\mathbb{R}^2), \quad \mathbb{P}(X \in B; Y \in C) = \int\int_{B\times C} f_{X,Y}(x,y)dxdy.$$

On rappelle en outre qu'on note $f_Y(y) \stackrel{\triangle}{=} \int_{\mathbb{R}} f_{X,Y}(x,y)dx$ la densité de la loi marginale de Y. Le fait que $\mathbb{P}_Y(dy) = f_Y(y)dy$ peut se retrouver en appliquant le théorème de Fubini :

$$\begin{aligned}\forall B \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}(Y \in B) &= \mathbb{P}(X \in \mathbb{R}; Y \in B) = \int\int_{\mathbb{R}\times B} f_{X,Y}(x,y)dxdy \\ &= \int_B \Big(\int_{\mathbb{R}} f_{X,Y}(x,y)dx\Big)dy = \int_B f_Y(y)dy.\end{aligned}$$

Ainsi Y à une loi à densité par rapport à la mesure de Lebesgue et donc $\mathbb{P}(Y=y)=0$ pour tout $y \in \mathbb{R}$. Donc la définition de l'espérance de X sachant Y donnée à la sous-section 1.2.2 n'a pas de sens. On pose donc

$$\mathbb{E}(X|Y=y) \stackrel{\triangle}{=} \int_{\mathbb{R}} x f_X^{Y=y}(x)dx = \int_{\mathbb{R}} x\,\frac{f_{X,Y}(x,y)}{f_Y(y)}dx. \tag{1.2}$$

De façon analogue à la sous-section 1.2.2, on définit ensuite $\varphi(y) = \mathbb{E}(X|Y=y)$, $y \in \mathbb{R}$, puis

$$\mathbb{E}(X|Y) \stackrel{\triangle}{=} \varphi(Y).$$

A nouveau, comme φ est mesurable la v.a. $\mathbb{E}(X|Y)$ est $\sigma(Y)$-mesurable.

Remarque 1. *C'est un exercice de montrer que φ est mesurable. En fait si f_Y est continue et $f_{X,Y}(x,\cdot)$ est continue pour tout x on peut voir que φ est continue donc mesurable. On peut gérer de façon analogue le cas continue par morceaux.*

Considérons la v.a. $\mathbb{E}(X|Y)$ définie à la sous-section 1.2.3. Soit $A \in \sigma(Y)$ on a $A = \{Y \in B\}$ pour un certain $B \in \mathcal{B}(\mathbb{R})$. En utilisant le théorème de Fubini, on a

$$\begin{aligned}\mathbb{E}\big[\mathbf{1}_A \mathbb{E}(X|Y)\big] &= \mathbb{E}\big[\mathbf{1}_{Y\in B}\,\varphi(Y)\big] = \int_B \mathbb{E}(X|Y=y) f_Y(y)dy \\ &= \int_B \Big(\int_{\mathbb{R}} x\,\frac{f_{X,Y}(x,y)}{f_Y(y)}dx\Big) f_Y(y)dy = \int\int_{\mathbb{R}\times B} x\, f_{X,Y}(x,y)\,dxdy \\ &= \int\int_{\mathbb{R}^2} 1_{y\in B} x\, f_{X,Y}(x,y)\,dxdy = \mathbb{E}\big[\mathbf{1}_{Y\in B}\,X\big] = \mathbb{E}\big[\mathbf{1}_A\,X\big].\end{aligned}$$

En résumé la v.a. $\mathbb{E}(X|Y)$ vérifie :

i) elle est $\sigma(Y)$-mesurable ;

ii) pour tout A dans $\sigma(Y)$ on a $\mathbb{E}\big[\mathbf{1}_A \mathbb{E}(X|Y)\big] = \mathbb{E}\big[\mathbf{1}_A\,X\big]$.

Ces deux caractéristiques i) et ii) vont être centrales pour définir l'espérance conditionnellement à une tribu.

1.3 Espérance conditionnellement à une tribu

A partir de maintenant et jusqu'à la fin du chapitre, $\mathcal{H}$ désigne une sous-tribu de $\mathcal{F}$. Pour $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$ on cherche à définir une v.a. réelle $\mathbb{E}(X|\mathcal{H})$ qui vérifie :

i) $\mathbb{E}(X|\mathcal{H})$ est $\mathcal{H}$-mesurable ;

ii) pour tout $A \in \mathcal{H}$, on a $\mathbb{E}[\mathbf{1}_A \mathbb{E}(X|\mathcal{H})] = \mathbb{E}[\mathbf{1}_A X]$.

On peut généraliser à un vecteur aléatoire (X est à valeurs dans $\mathbb{R}^d$) en définissant ses caractéristiques composante par composante et en utilisant la norme euclidienne $|\cdot|$ dans $\mathbb{R}^d$. Dans le cadre de ce chapitre, on se restreint à $d = 1$.

1.3.1 Première approche : le cadre L^2

Commençons par le cas $X \in L^2(\Omega, \mathcal{F}, \mathbb{P}) \subset L^1(\Omega, \mathcal{F}, \mathbb{P})$, i.e. $\mathbb{E}|X|^2 < +\infty$.

On peut alors utiliser des éléments de théorie hilbertienne pour définir $\mathbb{E}(X|\mathcal{H})$. On note $L^2(\Omega, \mathcal{H}, \mathbb{P})$ l'ensemble des variables aléatoires $\mathcal{H}$-mesurables et de carré intégrable. On rappelle les résultats suivants.

Lemme 1.3.1. *i) L'espace $L^2(\Omega, \mathcal{F}, \mathbb{P})$ muni du produit scalaire $(X, Y) \mapsto \mathbb{E}(XY)$ est un espace de Hilbert.*

ii) Le sous-espace $L^2(\Omega, \mathcal{H}, \mathbb{P}) \subset L^2(\Omega, \mathcal{F}, \mathbb{P})$ est un sous-espace fermé de $L^2(\Omega, \mathcal{F}, \mathbb{P})$.

Preuve:
Cf Jacod and Protter [2003], en particulier le théorème 22.3. ■

Pour un élément X de $L^2(\Omega, \mathcal{F}, \mathbb{P})$ on peut donc considérer son projeté orthogonal sur $L^2(\Omega, \mathcal{H}, \mathbb{P})$, cf. par exemple les théorème 22.6 et 22.7 dans Jacod and Protter [2003]. On décide de noter $\mathbb{E}(X|\mathcal{H})$ ce projeté orthogonal. Par nature, $\mathbb{E}(X|\mathcal{H})$ est $\mathcal{H}$-mesurable. De plus par orthogonalité $X - \mathbb{E}(X|\mathcal{H})$ avec le sous-espace $L^2(\Omega, \mathcal{H}, \mathbb{P})$, on a

$$\forall A \in \mathcal{H}, \quad \mathbb{E}[\{X - \mathbb{E}(X|\mathcal{H})\} \mathbf{1}_A] = 0.$$

c'est à dire

$$\forall A \in \mathcal{H}, \quad \mathbb{E}[\mathbf{1}_A \mathbb{E}(X|\mathcal{H})] = \mathbb{E}[\mathbf{1}_A X]. \tag{1.3}$$

La v.a. $\mathbb{E}(X|\mathcal{H})$ vérifie donc les points i) et ii) évoqués en début de section.

Dans le cadre L^2, $\mathbb{E}(X|\mathcal{H})$ peut être vue comme la meilleure approximation $\mathcal{H}$-mesurable de X au sens des moindres carrés. De plus sa norme L^2 est toujours inférieure ou égale à celle de X. En effet

$$||X||_{L^2}^2 = ||X - \mathbb{E}(X|\mathcal{H}) + \mathbb{E}(X|\mathcal{H})||_{L^2}^2 = ||X - \mathbb{E}(X|\mathcal{H})||_{L^2}^2 + ||\mathbb{E}(X|\mathcal{H})||_{L^2}^2 \geq ||\mathbb{E}(X|\mathcal{H})||_{L^2}^2.$$

Remarque 2. *Ainsi défini l'objet $\mathbb{E}(X|\mathcal{H})$ est unique à l' "égalité presque sûre près" (cf sous-section suivante pour une définition précise). C'est parce qu'en toute rigueur l'espace $L^2(\Omega, \mathcal{H}, \mathbb{P})$ par exemple est l'ensemble des classes d'équivalence pour la relation "égalité p.s. près" de v.a. $\mathcal{H}$-mesurables et de carré intégrable. C'est par un abus de langage généralisé et admis qu'on le considère comme l'ensemble des variables aléatoires $\mathcal{H}$-mesurables et de carré intégrable.*

1.3.2 Extension au cadre L^1 et premières propriétés

On peut également définir $\mathbb{E}(X|\mathcal{H})$ pour $X \in L^1(\Omega, \mathcal{F}, \mathbb{P}) = L^1$ dans la définition suivante.

Définition 1.3.1. *Soit X une variable aléatoire, supposée intégrable, i.e. $\mathbb{E}|X| < +\infty$. Il existe une v.a. Y appelée espérance de X sachant $\mathcal{H}$ (ou espérance de X conditionnellement à $\mathcal{H}$) vérifiant*

1. *Y est $\mathcal{H}$-mesurable,*
2. *Pour tout $A \in \mathcal{H}$, on a $\mathbb{E}(\mathbf{1}_A\, Y) = \mathbb{E}(\mathbf{1}_A\, X)$.*

Cette v.a. Y est unique à l'égalité p.s. près et se note $\mathbb{E}(X|\mathcal{H})$.

Preuve de l'existence de l'espérance conditionnelle

L'unicité sera traitée à part dans la proposition 1.3.3 ci-après, où on donnera un sens précis à l'égalité p.s. près.

— En utilisant la décomposition $X = X_+ - X_-$, $X_+ = \max(X, 0)$ et $X_- = -\min(X, 0)$, on voit qu'il suffit de traiter le cas $X \geq 0$, $X \in L^1$. Les parties positives et négatives ayant été traitées, on pourra montrer l'existence par

$$\mathbb{E}(X|\mathcal{H}) = \mathbb{E}(X_+|\mathcal{H}) - \mathbb{E}(X_-|\mathcal{H}).$$

et cet objet a bien les propriétés voulues par linéarité.

— Supposons donc $X \geq 0$, $X \in L^1$. On pose $X_n = X \wedge n$, $n \in \mathbb{N}$. Pour tout n la v.a. X_n est bornée donc dans $L^2(\Omega, \mathcal{F}, \mathbb{P})$. On définit donc $Y_n = \mathbb{E}(X_n|\mathcal{H})$ au sens L^2.

— Montrons que $X_n \geq 0$ pour tout n entraine que $Y_n \geq 0$ p.s. pour tout n.
Pour tout n, la v.a. Y_n est $\mathcal{H}$-mesurable donc $\{Y_n < 0\} \in \mathcal{H}$, donc en utilisant (1.3)

$$0 \geq \mathbb{E}[\mathbf{1}_{Y_n<0}\, Y_n] = \mathbb{E}[\mathbf{1}_{Y_n<0}\, X_n].$$

De plus en utilisant (1.3) de nouveau, on a

$$0 \underset{\text{p.s.}}{\leq} X_n \Rightarrow 0 \underset{\text{p.s.}}{\leq} \mathbf{1}_{Y_n<0}\, X_n \Rightarrow 0 \leq \mathbb{E}[\mathbf{1}_{Y_n<0}\, X_n] = \mathbb{E}[\mathbf{1}_{Y_n<0}\, Y_n].$$

Donc $\mathbb{E}[\mathbf{1}_{Y_n<0}\, Y_n] = 0$. Comme $\mathbf{1}_{Y_n<0}\, Y_n \geq 0$ p.s., cela entraine $\mathbf{1}_{Y_n<0}\, Y_n = 0$ p.s., donc $\mathbf{1}_{Y_n<0} = 0$ p.s., c'est à dire $Y_n \geq 0$ p.s..

— Pour s'en convaincre, supposons que $\mathbb{P}(Y_n < 0) > 0$ alors il existe $q_0 \in \mathbb{Q}_-^*$ t.q. $\mathbb{P}(Y_n \leq q_0) > 0$. En effet, s'il n'existe pas de tel rationnel $q \in \mathbb{Q}_-^*$, alors

$$\{Y_n < 0\} = \cup_{q\in\mathbb{Q}_-^*} \{Y_n \leq q\} \Rightarrow \mathbb{P}(Y_n < 0) \leq \sum_{q\in\mathbb{Q}_-^*} \mathbb{P}(Y_n \leq q) = 0.$$

Dans ce cas, on aurait $\mathbb{P}(Y_n < 0) = 0$, ce qui est absurde.
Donc il existe $q_0 \in \mathbb{Q}_-^*$ t.q. $\mathbb{P}(Y_n \leq q_0) > 0$ et

$$0 = \mathbb{E}[\mathbf{1}_{Y_n\leq q_0}\, Y_n] + \mathbb{E}[\mathbf{1}_{q_0<Y_n<0} Y_n].$$

De plus, $\mathbb{E}[\mathbf{1}_{q_0<Y_n<0} Y_n] \leq 0$ et $\mathbb{E}[\mathbf{1}_{Y_n\leq q_0}\, Y_n] \leq q_0 \mathbb{P}(Y_n \leq q_0) < 0$. On arrive à une absurdité, c'est donc que $\mathbb{P}(Y_n < 0) = 0$, i.e. $Y_n \geq 0$ p.s..

— Par ailleurs $X_{n+1} \geq X_n$ donc $X_{n+1} - X_n \geq 0$ pour tout n, donc

$$\forall n \in \mathbb{N}, \quad Y_{n+1} - Y_n = \mathbb{E}(X_{n+1} - X_n \,|\, \mathcal{H}) \geq 0 \ \text{ p.s.}$$

par les mêmes arguments que ci-dessus.

— La suite (Y_n) est donc p.s. positive et croissante. Posons donc $Y = \lim_n Y_n$ (cette limite existe p.s.). Notons que la v.a. Y est $\mathcal{H}$-mesurable car la limite préserve la mesurabilité.
— La suite (X_n) tend en croissant vers X. Donc par convergence monotone et en utilisant à nouveau (1.3) on a pour $A \in \mathcal{H}$,

$$\begin{aligned}\mathbb{E}[\mathbf{1}_A X] &= \int_A \lim_n X_n \, d\mathbb{P} = \lim_n \int_A X_n \, d\mathbb{P} = \lim_n \mathbb{E}[\mathbf{1}_A X_n] \\ &= \lim_n \mathbb{E}[\mathbf{1}_A Y_n] = \int_A \lim_n Y_n \, d\mathbb{P} = \mathbb{E}[\mathbf{1}_A Y].\end{aligned}$$

En résumé : Y est $\mathcal{H}$-mesurable et pour tout $A \in \mathcal{H}$, on a $\mathbb{E}(\mathbf{1}_A Y) = \mathbb{E}(\mathbf{1}_A X)$.

Proposition 1.3.2. *Dans la définition 1.3.1, la condition 2 peut être remplacée de façon équivalente par*
2' Pour toute v.a.r. Z bornée et $\mathcal{H}$-mesurable on a $\mathbb{E}(ZY) = \mathbb{E}(ZX)$.
Par conséquent, l'espérance conditionnelle $\mathbb{E}(X|\mathcal{H})$ vérifie $\mathbb{E}[Z\mathbb{E}(X|\mathcal{H})] = \mathbb{E}[ZX]$ pour toute v.a.r. Z bornée et $\mathcal{H}$-mesurable.

Preuve:
Pour l'une des implications, il suffit de prendre $Z = \mathbf{1}_A$ pour $A \in \mathcal{H}$. Pour l'autre implication, il s'agit d'approcher Z par des v.a. étagées. ■

Proposition 1.3.3. *Si Y et Y' vérifient les points 1) et 2) de la définition 1.3.1, on a $Y = Y'$ p.s., d'où l'égalité p.s. près.*

Preuve:
Pour tout $A \in \mathcal{H}$, on a $\mathbb{E}[\mathbf{1}_A Y] = \mathbb{E}[\mathbf{1}_A Y'] = \mathbb{E}[\mathbf{1}_A X]$ et donc

$$\mathbb{E}[\mathbf{1}_A(Y - Y')] = 0 = \mathbb{E}[\mathbf{1}_A(Y' - Y)], \quad \forall A \in \mathcal{H}. \tag{1.4}$$

Pour $\varepsilon > 0$, définissons $A_\varepsilon = \{|Y - Y'| \geq \varepsilon\}$. On a $A_\varepsilon \in \mathcal{H}$ car Y et Y' sont $\mathcal{H}$-mesurables et $(x, y) \mapsto |x - y|$ est continue donc mesurable. On a

$$\mathbb{E}[\mathbf{1}_{A_\varepsilon}|Y - Y'|] = \mathbb{E}[\mathbf{1}_{A_\varepsilon \cap \{Y - Y' > 0\}}(Y - Y') + \mathbf{1}_{A_\varepsilon \cap \{Y - Y' < 0\}}(Y' - Y)].$$

Mais $A_\varepsilon \cap \{Y - Y' > 0\}$ et $A_\varepsilon \cap \{Y - Y' < 0\}$ sont à nouveau dans $\mathcal{H}$ donc le terme de droite dans l'égalité ci-dessus vaut zéro par (1.4). Par ailleurs $\mathbb{E}[\mathbf{1}_{A_\varepsilon}|Y - Y'|] \geq \varepsilon \mathbb{P}(A_\varepsilon)$, d'où on déduit que $\mathbb{P}(A_\varepsilon) = 0$ pour tout $\varepsilon > 0$. C'est à dire

$$\begin{aligned}\{Y \neq Y'\} &= \{\omega \in \Omega : \exists q \in \mathbb{Q}_+^* \text{ avec } |Y(\omega) - Y'(\omega)| > q\} = \textstyle\bigcup_{q \in \mathbb{Q}_+^*} \{\omega \in \Omega : |Y(\omega) - Y'(\omega)| > q\} \\ &= \textstyle\bigcup_{q \in \mathbb{Q}_+^*} \{|Y - Y'| > q\} \in \mathcal{F},\end{aligned}$$

et $\mathbb{P}(\cup_{q \in \mathbb{Q}_+^*} \{|Y - Y'| > q\}) \leq \sum_{q \in \mathbb{Q}_+^*} \mathbb{P}(A_q) = 0$. Donc $\mathbb{P}(Y \neq Y') = 0$, i.e. $Y = Y'$ p.s. ■

Lemme 1.3.4. *Pour $X \in L^1$ on a $\mathbb{E}(X|\mathcal{H}) \in L^1$.*

On liste maintenant une série de propriétés de l'espérance conditionnellement à une tribu. Dans les propositions ci-dessous on considère que $X, Y \in L^1(\Omega, \mathcal{F}, \mathbb{P})$.

Proposition 1.3.5. *On a*
i) (linéarité) Pour $a, b \in \mathbb{R}$,

$$\mathbb{E}(aX + bY|\mathcal{H}) = a\mathbb{E}(X|\mathcal{H}) + b\mathbb{E}(Y|\mathcal{H}).$$

ii) (préservation relation d'ordre) Si $X \underset{\text{p.s.}}{\geq} 0$ *alors*

$$\mathbb{E}(X|\mathcal{H}) \underset{\text{p.s.}}{\geq} 0.$$

iii) (espérance de l'espérance cond)

$$\mathbb{E}[\mathbb{E}(X|\mathcal{H})] = \mathbb{E}(X).$$

iv) (calcul par mesurabilité) Si X *est* $\mathcal{H}$*-mesurable alors*

$$\mathbb{E}(X|\mathcal{H}) \overset{\text{p.s.}}{=} X.$$

v) (calcul par mesurabilité) Si Y *est* $\mathcal{H}$*-mesurable et* X *v.a. intégrable quelconque, alors*

$$\mathbb{E}(YX|\mathcal{H}) \overset{\text{p.s.}}{=} Y\mathbb{E}(X|\mathcal{H}).$$

vi) (calcul par indépendance) Si X *est indépendante de* $\mathcal{H}$ *(i.e.* $X \perp \mathbf{1}_A, \forall A \in \mathcal{H}$*), alors*

$$\mathbb{E}(X|\mathcal{H}) \overset{\text{p.s.}}{=} \mathbb{E}(X).$$

vii) (calcul par itération) Si $\mathcal{G}$ *est une sous-tribu avec* $\mathcal{H} \subset \mathcal{G} \subset \mathcal{F}$*, alors*

$$\mathbb{E}\big[\mathbb{E}(X|\mathcal{G}) \,|\, \mathcal{H}\big] \overset{\text{p.s.}}{=} \mathbb{E}(X|\mathcal{H}) \overset{\text{p.s.}}{=} \mathbb{E}\big[\mathbb{E}(X|\mathcal{H}) \,|\, \mathcal{G}\big].$$

Preuve:

i) Pour tout $A \in \mathcal{H}$, on a par linéarité de l'espérance, puis (1.3),

$$\mathbb{E}(1_A(a\mathbb{E}(X|\mathcal{H})+b\mathbb{E}(Y|\mathcal{H})) = a\mathbb{E}(1_A\mathbb{E}(X|\mathcal{H}))+b\mathbb{E}(1_A\mathbb{E}(Y|\mathcal{H})) = a\mathbb{E}(1_AX)+b\mathbb{E}(1_AY) = \mathbb{E}(1_A(aX+bY)).$$

Comme l'espérance conditionnelle est l'unique v.a. vérifiant $\mathbb{E}(1_A(aX+bY)) = \mathbb{E}(1_A\mathbb{E}(aX+bY|\mathcal{H}))$, on obtient la relation désirée.

ii, iv, v, vi) voir TD.
iii) Il suffit de prendre $A = \Omega$ dans le point 2) de la définition 1.3.1.
vii) La deuxième partie de l'égalité découle simplement du point iii) car $\mathbb{E}(X|\mathcal{H})$ est $\mathcal{H}$-mesurable, donc $\mathcal{G}$-mesurable. Montrons la première partie. La v.a. $\mathbb{E}(X|\mathcal{H})$ est bien $\mathcal{H}$-mesurable. Soit $A \in \mathcal{H}$, on a $A \in \mathcal{G}$ puisque $\mathcal{H} \subset \mathcal{G}$. Donc on a

$$\mathbb{E}[\mathbf{1}_A\mathbb{E}(X|\mathcal{G})] = \mathbb{E}[\mathbf{1}_AX] = \mathbb{E}[\mathbf{1}_A\mathbb{E}(X|\mathcal{H})].$$

En résumé, 1) $\mathbb{E}(X|\mathcal{H})$ est $\mathcal{H}$-mesurable. 2) Pour tout $A \in \mathcal{H}$ on a $\mathbb{E}[\mathbf{1}_A\mathbb{E}(X|\mathcal{H})] = \mathbb{E}[\mathbf{1}_A\mathbb{E}(X|\mathcal{G})]$. Par unicité ceci montre

$$\mathbb{E}\big[\mathbb{E}(X|\mathcal{G}) \,|\, \mathcal{H}\big] = \mathbb{E}(X|\mathcal{H}) \quad \text{p.s.}$$

■

Définition 1.3.2. *Pour* $A \in \mathcal{F}$*, on note* $\mathbb{P}(A|\mathcal{H})$ *la variable aléatoire* $\mathbb{E}(\mathbf{1}_A|\mathcal{H})$*. C'est la probabilité de l'évènement* A *sachant la sous-tribu* $\mathcal{H}$*.*

1.3.3 Espérance d'une variable aléatoire conditionnellement à une autre

Définition 1.3.3. *Soient* X *et* Y *définies sur* $(\Omega, \mathcal{F}, \mathbb{P})$*, avec* X *intégrable. On note*

$$\mathbb{E}(X|Y) \overset{\triangle}{=} \mathbb{E}[X \,|\, \sigma(Y)]$$

où on rappelle que $\sigma(Y)$ *est la tribu engendrée par* Y*.*

On a besoin du lemme suivant.

Lemme 1.3.6 (Lemme de Doob)**.** *Soit Y v.a. Une variable aléatoire Z est $\sigma(Y)$-mesurable si et seulement si il existe φ mesurable t.q. $Z = \varphi(Y)$.*

Preuve:
Cf Lemme VI.3.1 dans Barbe and Ledoux [2012]. ■

Du lemme de Doob découle naturellement la proposition suivante.

Proposition 1.3.7. *Dans le contexte de la définition 1.3.3 il existe une fonction φ mesurable telle que*

$$\mathbb{E}(X|Y) = \varphi(Y).$$

Cela nous amène à poser la notation

$$\mathbb{E}(\, X \,|\, Y = y) \stackrel{\triangle}{=} \varphi(y), \tag{1.5}$$

avec la fonction φ en jeu dans la proposition.

Cas à densité bivariée

Considérons $\mathbb{E}(X|Y)$ définie dans la sous-section 1.2.3. On a déjà vu que cette v.a. vérifie :
— i) $\mathbb{E}(X|Y)$ est $\sigma(Y)$-mesurable.
— ii) Pour tout A dans $\sigma(Y)$ on a $\mathbb{E}\big[\mathbf{1}_A \mathbb{E}(X|Y)\big] = \mathbb{E}\big[\mathbf{1}_A\, X\big]$.
Par unicité de l'espérance conditionnelle, Déf 1.3.1, $\mathbb{E}(X|Y) = \mathbb{E}(X|\sigma(Y))$ et φ de la proposition 1.3.7 est la fonction déjà rencontrée en (1.2) et définie par

$$\varphi(y) = \mathbb{E}(\, X \,|\, Y = y) = \int_{\mathbb{R}} x\, \frac{f_{X,Y}(x,y)}{f_Y(y)} dx.$$

Cas discret

Soit $y \in E'$ (on reprend les notations de la sous-section 1.2.2). Naturellement, $\{Y = y\} \in \sigma(Y)$. En utilisant les nouvelles définitions de $\mathbb{E}(X|Y)$ et $\mathbb{E}(\, X \,|\, Y = y)$, on a

$$\mathbb{E}[X\mathbf{1}_{\{Y=y\}}] = \mathbb{E}[\mathbf{1}_{\{Y=y\}}\mathbb{E}(X|Y)] = \sum_{z\in E'} \mathbf{1}_{z=y}\mathbb{E}(\, X \,|\, Y = z)\mathbb{P}(Y = z) = \mathbb{E}(\, X \,|\, Y = y)\mathbb{P}(Y = y).$$

Donc $\mathbb{E}(\, X \,|\, Y = y) = \frac{\mathbb{E}[X\mathbf{1}_{\{Y=y\}}]}{\mathbb{P}(Y=y)}$. En TD, on montre que $\mathbb{E}(X|Y)$ vérifie :
— i) $\mathbb{E}(X|Y)$ est $\sigma(Y)$-mesurable.
— ii) Pour tout A dans $\sigma(Y)$ on a $\mathbb{E}\big[\mathbf{1}_A \mathbb{E}(X|Y)\big] = \mathbb{E}\big[\mathbf{1}_A\, X\big]$.
Par unicité de l'espérance conditionnelle, Déf 1.3.1, $\mathbb{E}(X|Y) = \mathbb{E}(X|\sigma(Y))$ et φ de la proposition 1.3.7 est la fonction déjà rencontrée en (1.1) et définie par

$$\varphi(y) = \mathbb{E}(\, X \,|\, Y = y) = \sum_{x\in E} x \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)}.$$

1.3.4 Autres propriétés

Proposition 1.3.8. *Soient X et Y des variables aléatoires définies sur $(\Omega, \mathcal{F}, \mathbb{P})$ et f mesurable telle que $f(X,Y) \in L^1$. Supposons que X est $\mathcal{H}$-mesurable et que Y est indépendante de $\mathcal{H}$ (donc de X). On définit la fonction φ par $\varphi(x) = \mathbb{E}[f(x,Y)]$. Alors φ est mesurable sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ et on a p.s. $\mathbb{E}[f(X,Y) \,|\, \mathcal{H}] = \varphi(X)$.*

Preuve:
Cf Jacod and Protter [2003], Exercice 23.7, ou Lamberton and Lapeyre [1997] proposition A.2.5. ■

Remarque 3. *Autrement dit, sous les hypothèses précédentes, on peut calculer $\mathbb{E}[f(X,Y) \,|\, \mathcal{H}]$ comme si X est constant.*

Remarque 4. *En choisissant $f(x,y) = xy$, pour $X \perp Y$, on retrouve le point v) de la propriété 1.3.5 :*

$$\varphi(x) = x\mathbb{E}(Y) \Rightarrow \mathbb{E}(XY|\mathcal{H}) = X\mathbb{E}(Y).$$

Pour $x = 1$, on retrouve le point vi) de la propriété 1.3.5 :

$$\mathbb{E}(Y|\mathcal{H}) = \mathbb{E}(1 \times Y|\mathcal{H}) = \mathbb{E}(f(1,Y)|\mathcal{H}) = \varphi(1) = \mathbb{E}(Y).$$

Théorème 1.3.9. *1) (Convergence monotone) : Si (X_n) est une suite de v.a. positives qui tend en croissant vers $X \in L^1$ alors*

$$\mathbb{E}(X_n|\mathcal{H}) \xrightarrow[n\to+\infty]{\text{p.s.}} \mathbb{E}(X|\mathcal{H}).$$

2) (Fatou) : Si $X_n \geq Z$ pour tout n avec $Z \in L^1$ et $\mathbb{E}|X_n| < \infty$ pour tout n et $\mathbb{E}|\liminf_n X_n| < \infty$ alors

$$\mathbb{E}(\liminf_n X_n \,|\, \mathcal{H}) \leq \liminf_n \mathbb{E}(X_n \,|\, \mathcal{H}) \quad \text{p.s.}.$$

3) (Convergence dominée) : Si

$$X_n \xrightarrow[n\to+\infty]{\text{p.s.}} X \in L^1.$$

et s'il existe $Z \in L^1$ t.q. $|X_n| \leq Z$ p.s. pour tout n alors,

$$\mathbb{E}(X_n|\mathcal{H}) \xrightarrow[n\to+\infty]{\text{p.s.}} \mathbb{E}(X|\mathcal{H}).$$

4) (Jensen) : Si $X \in L^1$ et $\varphi : \mathbb{R} \to \mathbb{R}$ est mesurable convexe avec $\varphi(X) \in L^1$ alors

$$\varphi(\mathbb{E}(X|\mathcal{H})) \leq \mathbb{E}(\varphi(X) \,|\, \mathcal{H}) \quad \text{p.s.}$$

Preuve:
Cf Jacod and Protter [2003], théorèmes 23.8 et 23.9. ■

1.4 Processus stochastiques

On introduit la notion de processus stochastique, et on donne une série de définitions générales liées à cette notion. On explore quelques exemples usuels tels que les chaînes de Markov, les processus de Poisson.

Dans les définitions qui suivent $(E, \mathcal{E})$ désigne un espace mesurable.

Définition 1.4.1 (Processus aléatoire)**.** *On appelle processus aléatoire (ou stochastique) une famille $X = (X_\theta)_{\theta\in\Theta}$ de variables aléatoires X_θ à valeurs dans $(E, \mathcal{E})$ et définies sur un même espace de probabilités $(\Omega, \mathcal{F}, \mathbb{P})$, indexée par $\theta \in \Theta$ où Θ est un ensemble. C'est à dire que $X_\theta : \Omega \to E$ est une application mesurable pour tout $\theta \in \Theta$.*

Remarque 5. *Si Θ est fini ou dénombrable (ex : $\Theta = \mathbb{N}, \mathbb{Z}, \ldots$) on parle de processus à temps discret.*

Si Θ a la puissance du continu (ex : $\Theta = \mathbb{R}_+, \mathbb{R}, \mathbb{R}^2, \ldots$) on parle de processus à temps continu.

Si θ représente le temps, X représente l'évolution temporelle d'une grandeur aléatoire.

Si θ représente un espace, X représente l'évolution spatiale d'une grandeur aléatoire : on parle de champ aléatoire dans ce cas.

L'espace E est appelé l'espace d'état du processus X (on dit aussi que le processus X est à valeurs dans E).

Il y a deux autres façons de voir un processus $X = (X_\theta)_{\theta\in\Theta}$ défini sur $(\Omega, \mathcal{F}, \mathbb{P})$ et à valeurs dans E.

Remarque 6. *On peut voir X comme une application bivariée :*

$$\begin{array}{rccc} X: & \Theta\times\Omega & \to & E \\ & (\theta,\omega) & \mapsto & X_\theta(\omega) \end{array}$$

Notons que sans plus d'hypothèse sa mesurabilité de $\Theta \times \Omega$ vers E n'est pas claire.

Remarque 7. *On peut voir X comme une application de Ω vers l'espace fonctionnel E^Θ (l'ensemble des fonctions de Θ vers E) :*

$$\begin{array}{rcccl} X:\Omega & \to & E^\Theta & & \\ \omega & \mapsto & X_\cdot(\omega): & \Theta & \to & E \\ & & & \theta & \mapsto & X_\theta(\omega) \end{array}$$

Pour $\omega \in \Omega$ la fonction $X_\cdot(\omega)$, élément de E^Θ, est appelée une trajectoire du processus X (c'est la trajectoire associée à l'aléa ω).

Pour voir X comme une variable aléatoire à valeurs dans l' "espace des trajectoires" E^Θ il faut mettre une tribu sur E^Θ.

Dans ce qui suit, sauf précision contraire, on considère un processus à valeurs dans $E \subset \mathbb{R}$ et défini sur un certain espace de probabilités. On suppose que l'addition fait sens pour les éléments de l'ensemble Θ, mais dans les deux définitions suivantes on ne suppose pas que c'est un groupe additif, ni qu'il est muni d'une structure d'ordre.

Définition 1.4.2 (Loi fini-dimensionnelle)**.** *Une loi fini-dimensionnelle en $\theta_1, \ldots, \theta_n$ est la loi du vecteur aléatoire $X_{\theta_1}, \ldots, X_{\theta_n}$ généralement caractérisée par sa fonction de répartition*

$$F_{\theta_1,\ldots,\theta_n}(x_1, \ldots, x_n) = \mathbb{P}(X_{\theta_1} \leq x_1, \ldots, X_{\theta_n} \leq x_n),$$

sa fonction de densité

$$f_{\theta_1,\ldots,\theta_n}(x_1, \ldots, x_n) = \frac{\partial^n F_{\theta_1,\ldots,\theta_n}(x_1, \ldots, x_n)}{\partial x_1 \ldots \partial x_n},$$

ou sa fonction de masse de probabilité

$$P_{\theta_1,\ldots,\theta_n}(x_1, \ldots, x_n) = \mathbb{P}(X_{\theta_1} = x_1, \ldots, X_{\theta_n} = x_n).$$

L'ensemble des lois fini-dimensionnelles est la famille des $F_{\theta_1,\ldots,\theta_n}$ pour tout $n \geq 1$, pour tout $\theta_i \in \Theta$.

1.4.1 Définitions usuelles

Dorénavant on suppose qu'il existe une relation d'ordre sur Θ : l'indice $\theta \in \Theta$ représente le temps. Typiquement, on a $\Theta = \mathbb{N}$ ou $\Theta = \mathbb{R}_+$.

Définition 1.4.3 (Processus stationnaire). *Un processus $X = (X_\theta)_{\theta\in\Theta}$ est dit stationnaire si pour tout $n \in \mathbb{N}^*$, pour tout $\theta_1, \dots, \theta_n \in \Theta$, et pour tout $h \in \Theta$ avec $\theta_i + h \in \Theta$, $\forall 1 \leq i \leq n$, les vecteurs $(X_{\theta_1+h}, \dots, X_{\theta_n+h})'$ et $(X_{\theta_1}, \dots, X_{\theta_n})'$ ont même loi.*

Définition 1.4.4 (Processus à accroissements stationnaires). *Un processus $X = (X_\theta)_{\theta\in\Theta}$ est à accroissements stationnaires si la loi de $X_{t+\theta} - X_t$ ne dépend pas de t, pour tous $\theta, t \in \Theta$ t.q. $t + \theta \in \Theta$.*

Définition 1.4.5 (Processus à accroissements indépendants). *Un processus $X = (X_\theta)_{\theta\in\Theta}$ est dit à accroissements indépendants si pour tout $\theta_1 < \ldots < \theta_k$ dans Θ les v.a. $X_{\theta_2} - X_{\theta_1}, \dots, X_{\theta_k} - X_{\theta_{k-1}}$ sont mutuellement indépendantes.*

Définition 1.4.6 (Filtration). *Une filtration $(\mathcal{F}_\theta)_{\theta\in\Theta}$ sur un espace de probabilités $(\Omega, \mathcal{F}, \mathbb{P})$ est un ensemble croissant de sous-tribus $\mathcal{F}_\theta$ de $\mathcal{F}$, i.e. pour tout $s \leq t$ dans Θ, on a $\mathcal{F}_s \subset \mathcal{F}_t \subset \mathcal{F}$.*

Définition 1.4.7 (Processus adapté). *On dit qu'un processus $X = (X_\theta)_{\theta\in\Theta}$ est adapté à une filtration $(\mathcal{F}_\theta)_{\theta\in\Theta}$ si pour tout $\theta \in \Theta$ la v.a. X_θ est $\mathcal{F}_\theta$-mesurable.*

Définition 1.4.8 (Filtration naturelle). *Soit $X = (X_\theta)_{\theta\in\Theta}$ un processus aléatoire. Définissons pour tout $\theta \in \Theta$ la tribu $\mathcal{F}_\theta^X$ par $\mathcal{F}_\theta^X = \sigma(X_s : s \leq \theta)$, où $\sigma(X_s : s \leq \theta)$ est la plus petite tribu qui rend mesurable tous les X_s pour $s \leq \theta$*[*]*.*
La filtration $(\mathcal{F}_\theta^X)$ est appelée filtration naturelle du processus X. L'élément $\mathcal{F}_\theta^X$ de la filtration représente l'ensemble des évènements qu'on peut décrire en connaissant les trajectoires du processus jusqu'à l'instant θ.

Remarque 8.

— *$(\mathcal{F}_\theta^X)_{\theta\in\Theta}$ est une filtration puisque pour tout $t_1 \leq t_2$,*

$$s \leq t_1 \Rightarrow s \leq t_2 \Rightarrow \sigma(X_s : s \leq t_1) \subset \sigma(X_s : s \leq t_2) \Leftrightarrow \mathcal{F}_{t_1}^X \subset \mathcal{F}_{t_2}^X.$$

— *X est adapté à $(\mathcal{F}_\theta^X)$ puisque pour tout θ, $\sigma(X_\theta) \subset \sigma(X_s : s \leq \theta)$. Donc X_θ est bien $\mathcal{F}_\theta^X$-mesurable.*

1.4.2 Propriété de Markov

On se tourne maintenant vers la notion de processus de Markov. On rappelle la notation de probabilité conditionnelle introduite dans la définition 1.3.2.

Définition 1.4.9. *Soit $(\mathcal{F}_\theta)_{\theta\in\Theta}$ une filtration et $X = (X_\theta)_{\theta\in\Theta}$ un processus adapté. On dit que X est $(\mathcal{F}_\theta)$-Markov si pour tout $s < t \in \Theta$, et tout $B \in \mathcal{E}$ on a*

$$\mathbb{P}(X_t \in B \,|\, \mathcal{F}_s) = \mathbb{P}(X_t \in B \,|\, X_s). \tag{1.6}$$

Quand la filtration $(\mathcal{F}_\theta)_{\theta\in\Theta}$ est la filtration naturelle $(\mathcal{F}_\theta^X)_{\theta\in\Theta}$, X est un processus de Markov lorsque pour tout $s < t \in \Theta$, et tout $B \in \mathcal{E}$, on a

$$\mathbb{P}(X_t \in B \,|\, \mathcal{F}_s^X) = \mathbb{P}(X_t \in B \,|\, X_s). \tag{1.7}$$

Autrement dit, il existe une fonction g_B telle que (1.7) vaut $\mathbb{P}(X_t \in B \,|\, X_s) = g_B(s, t, X_s)$.

∗. cette tribu existe car on peut la définir comme étant la plus petite contenant $\mathcal{C}_\theta = \{X_s^{-1}(A),\ A \in \mathcal{E},\ s \leq \theta\}$.

Remarque 9. *Dans le contexte, où E est dénombrable, le caractère Markov (1.7) se réécrit $\forall n \in \mathbb{N}$, pour tous $x_1, \ldots, x_n, x_{n+1} \in E$, on a*

$$\forall 0 \leq t_1 \leq \ldots \leq t_n \leq t_{n+1}, \mathbb{P}(X_{t_{n+1}} = x_{n+1} | X_{t_n} = x_n, \ldots, X_{t_1} = x_1) = \mathbb{P}(X_{t_{n+1}} = x_{n+1} | X_{t_n} = x_n),$$

dès que $\mathbb{P}(X_{t_n} = x_n, \ldots, X_{t_1} = x_1) > 0$.

Autrement dit, le "futur" en t_{n+1} ne dépend que du "présent" en t_n et non du "passé" en $t_1, \ldots, t_n$.

Proposition 1.4.1. *Si $X = (X_\theta)_{\theta \in \Theta}$ est $(\mathcal{F}_\theta)$-Markov pour une certaine filtration $(\mathcal{F}_\theta)_{\theta \in \Theta}$, alors il est $(\mathcal{F}_\theta^X)$-Markov.*

Définition 1.4.10. *Un processus de Markov $X = (X_\theta)_{\theta \in \Theta}$ est dit de Markov homogène si pour tout $s < t \in \Theta$, et tout $B \in \mathcal{E}$, il existe une fonction $g_B(t-s, \cdot)$, telle que (1.7) se réécrit*

$$\mathbb{P}(X_t \in B \,|\, \mathcal{F}_s^X) = g_B(t-s, X_s). \tag{1.8}$$

C'est à dire $g_B(t-s, \cdot)$ dépend de l'écart $t-s$ mais pas de s. Dans ce cas, on a pour tout $s < t \in \Theta$ et tout $x \in E$,

$$\mathbb{P}(X_t \in B \,|\, X_s = x, \ldots) = g_B(t-s, x) = \mathbb{P}(X_{t-s} \in B \,|\, X_0 = x). \tag{1.9}$$

Remarque 10. *A nouveau, dans le cas où E est dénombrable, la définition de Markov homogène (1.9) se réécrit pour tout $s < t \in \Theta$ et tous $x, y \in E$*

$$\mathbb{P}(X_t = y | X_s = x) = p(t-s, x, y)$$

où $p_{t-s}(x, y)$ dépend de x, de y et de l'écart $t-s$ mais pas de l'instant s.

Nom	Markov (inhomogène)	Markov homogène
définition	$\mathbb{P}(X_t \in B \,\|\, \mathcal{F}_s^X) = g_B(s, t, X_s)$	$\mathbb{P}(X_t \in B \,\|\, \mathcal{F}_s^X) = g_B(t-s, X_s)$
E dénombrable	$\mathbb{P}(X_{t_{n+1}} = x_{n+1} \| X_{t_n} = x_n, \ldots) = p(t_n, t_{n+1}, x_n, x_{n+1})$	$\mathbb{P}(X_t = y \| X_s = x) = p(t-s, x, y)$

TABLE 1.2 – Résumé des propriétés Markov

1.4.3 Deux exemples usuels

Définition 1.4.11 (Chaine de Markov homogène)**.** *Une chaîne de Markov est un processus de Markov homogène à valeurs dans E dénombrable et indexé par $n \in \mathbb{N}$.*
Autrement dit, pour tout $n < m$, la probabilité d'être dans l'état y en m ne dépend que du dernier état x à la date n pour tout $x, y \in E$,

$$\mathbb{P}(X_m = y | X_n = x_n, \ldots, X_0 = x_0) = \mathbb{P}(X_m = y | X_n = x_n) = \mathbb{P}(X_{m-n} = y | X_0 = x_n) = p(m-n, x_n, y).$$

On notera aussi souvent $X = (X_n)_{n \geq 0}$, le n indiquant la nature discrète du temps.

Définition 1.4.12 (Processus de Poisson homogène)**.** *Considérons une suite de variables X_i i.i.d. de loi exponentielle $Exp(\lambda)$. Le processus N défini en t par*

$$N_t = \max(n \in \mathbb{N}, T_n \leq t), T_n = \sum_{i=1}^{n} X_i.$$

est appelé processus de Poisson homogène. L'instant T_n est appelé nème temps d'occurrence. Les variables X_i sont appelées temps d'inter-occurrence.

Par simplicité, dans la suite de ce cours, une chaine de Markov homogène sera appelée chaine de Markov, et un processus de Poisson homogène sera appelé processus de Poisson.